

SI231B: Matrix Computations, 2024 Spring

Homework Set #1

Acknowledgements:

- 1) Deadline: **2024-03-21 23:59:59**
- 2) You have 5 “free days” in total for late submission.
- 3) Submit your homework in **Homework 1** on **Gradescope**. Entry Code: **NPK2YD**. Make sure that you have correctly select pages for each problem. If not, you probably will get 0 point.

Problem 1. (Range Space and Rank) (15 points)

Given $\mathbf{A} \in \mathbb{R}^{m \times k}$ and $\mathbf{B} \in \mathbb{R}^{k \times n}$, prove that

- 1) $\dim \mathcal{R}(\mathbf{AB}) \leq \dim \mathcal{R}(\mathbf{A})$. (3 points)
- 2) $\dim \mathcal{R}(\mathbf{AB}) = \dim \mathcal{R}(\mathbf{A})$ if \mathbf{B} has full row rank. (3 points)
- 3) Based on the above two results, show that

$$\text{rank}(\mathbf{AB}) \leq \min\{\text{rank}(\mathbf{A}), \text{rank}(\mathbf{B})\}$$

and the equality attains if the columns of \mathbf{A} are linearly independent or the rows of \mathbf{B} are linearly independent. (5 points)

Hint: It suffices to show $\dim \mathcal{R}(\mathbf{AB}) \leq \dim \mathcal{R}(\mathbf{A})$ and $\dim \mathcal{R}(\mathbf{B}^T \mathbf{A}^T) \leq \dim \mathcal{R}(\mathbf{B}^T)$.

- 4) $\dim \mathcal{R}(\mathbf{AB}) = k$ if \mathbf{A} has full column rank and \mathbf{B} has full row rank. (4 points)

- 1) 要证明 $\dim \mathcal{R}(\mathbf{AB}) \leq \dim \mathcal{R}(\mathbf{A})$, 我们可以利用矩阵乘法的性质以及列空间的定义。

设 A 是一个 $m \times k$ 的矩阵, B 是一个 $k \times n$ 的矩阵。我们知道, AB 的列空间是由 A 的列向量经过 B 的变换而得到的。由于 B 是一个 $k \times n$ 的矩阵, 它将 A 的列向量投影到一个 n 维的子空间中。根据线性代数的基本原理, 我们知道, 任何 m 维的向量空间在进行线性变换后得到的子空间的维度不会超过 m 。因此, AB 的列空间的维度不会超过 A 的列空间的维度。

因此, 我们得出 $\dim \mathcal{R}(\mathbf{AB}) \leq \dim \mathcal{R}(\mathbf{A})$ 。

- 2) 对于线性方程组 $\mathbf{AB}x = 0$ 与 $\mathbf{B}x = 0$, 因为 B 是满秩, 所以两个线性方程组同解。所以 $\mathcal{R}(\mathbf{AB}) = \mathcal{R}(\mathbf{B})$
- 3) \mathbf{AB} 中的行向量是 \mathbf{A} 中行向量的线性组合, 同时也是 \mathbf{A} 中行向量的极大无关组的线性组合。如果把 \mathbf{AB} 中的所有行向量与 \mathbf{A} 中的极大无关组写成一个 n 维向量, 那么这个极大无关组也是这个 n 维向量的极大无关组。 \mathbf{AB} 的极大无关组应该小于或者等于 \mathbf{A} 中行向量的极大无关组所包含的向量数量, 而极大无关组中向量的数量就是原向量组的秩。 B 同理可证, 结果就是 $\mathcal{R}(\mathbf{AB}) \leq \min(\dim \mathcal{R}(\mathbf{A}), \dim \mathcal{R}(\mathbf{B}))$

4) 根据 1) , 2) , 3) 的结论可以得出, $\dim R(A) = \text{rank}(A) = k, \dim R(B) = k, \dim(R(AB)) = \min(R(A), R(B)) = k$

Problem 2. (Vector Norms) (15 points)

Recall that we talked about the vector norm in class. For any $\mathbf{x} = [x_1, \dots, x_n]^\top \in \mathbb{R}^n$, please prove the following arguments:

- 1) The maximum norm is defined to be

$$\|\mathbf{x}\|_\infty = \lim_{p \rightarrow \infty} \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}.$$

Show that

$$\|\mathbf{x}\|_\infty = \max_{i=1, \dots, n} |x_i|.$$

(5 points)

- 2) Verify the following inequality chain

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{n} \|\mathbf{x}\|_2 \leq n \|\mathbf{x}\|_\infty.$$

(5 points)

- 3) Show that

$$\|\mathbf{x}\|_1 \|\mathbf{x}\|_\infty \leq \frac{1 + \sqrt{n}}{2} \|\mathbf{x}\|_2^2.$$

(5 points)

- 1) 最大范数 $\|x\|_\infty$ 是指随着 p 趋向无穷大时的极限:

$$\|x\|_\infty = \lim_{p \rightarrow \infty} \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

我们需要证明 $\|x\|_\infty = \max_{i=1, \dots, n} |x_i|$ 。

证明过程如下: - 首先, 考虑 $|x_i|^p$ 当 $p \rightarrow \infty$ 时的情况。对于任意的 $x_i \neq 0$, $|x_i|^p$ 随着 p 的增大而趋近于 $|x_i|^\infty = |x_i|$, 而对于 $x_i = 0$, $|x_i|^p$ 为 0。- 因此, 当 p 趋向无穷大时, $(\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$ 的值将趋近于 $\max_{i=1, \dots, n} |x_i|$ 。- 因此, 最大范数 $\|x\|_\infty$ 就是 $|x_i|$ 中的最大值, 即 $\|x\|_\infty = \max_{i=1, \dots, n} |x_i|$ 。

- 2) 验证不等式链:

$$\|x\|_\infty \leq \|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2 \leq n \|x\|_\infty$$

证明: $\|x\|_\infty \leq \|x\|_2$: 最大范数是向量的所有分量的绝对值中的最大值, 因此最大范数不会超过欧几里得范数。 $\|x\|_2 \leq \|x\|_1$: 欧几里得范数是向量的所有分量的平方和的平方根, 而曼哈顿范数是向量的所有分量的绝对值之和。显然, 平方和的平方根不会超过绝对值之和。 $\|x\|_1 \leq \sqrt{n} \|x\|_2$: 根据柯西-施瓦茨不等式, 我们有 $|x_1| + |x_2| + \dots + |x_n| \leq \sqrt{n}(|x_1|^2 + |x_2|^2 + \dots + |x_n|^2)^{\frac{1}{2}} = \sqrt{n} \|x\|_2 \leq n \|x\|_\infty$: 由于最大范数是向量的所有分量的最大值, 因此欧几里得范数不会超过最大范数的 \sqrt{n} 倍。

- 3) 证明:- 根据柯西-施瓦茨不等式, 我们有 $\|x\|_1 \|x\|_\infty \leq \|x\|_2^2$ 。- 另一方面, 我们可以将 $\sqrt{n} \|x\|_2 \geq \|x\|_1$ 代入, 得到 $\|x\|_1 \leq \frac{1+\sqrt{n}}{2} \|x\|_2$ 。- 因此, 将这两个不等式结合起来, 我们得到 $\|x\|_1 \|x\|_\infty \leq \frac{1+\sqrt{n}}{2} \|x\|_2^2$ 。

Problem 3. (Direct Sum of Subspaces) (20 points)

A vector space V is the (*internal*) *direct sum* of a family $\mathcal{F} = \{S_1, \dots, S_n\}$ of subspaces of V , written $V = \oplus_{i=1}^n S_i = S_1 \oplus \dots \oplus S_n$ if the following two conditions hold:

- V is the sum of the family \mathcal{F} : $V = \sum_{i=1}^n S_i$,
- for each i , $S_i \cap \left(\sum_{j \neq i} S_j\right) = \{0\}$.

For example, a vector space V is the direct sum of a subspace S and its orthogonal complement S^\perp : $V = S \oplus S^\perp$. \mathbb{R}^3 is the direct sum of any three non-coplanar lines.

1) Determine which of the following sums are direct sums. Briefly explain why.

- \mathbb{R}^3 is the sum of any two distinct planes. (1 point)
- $\mathbb{R}^{n \times n}$ is the sum of the subspace of upper-triangular matrices and the subspace of lower-triangular matrices. (2 points)
- $\mathbb{R}^{n \times n}$ is the sum of the subspace of symmetric matrices and the subspace of skew-symmetric matrices. (A square matrix \mathbf{A} is called skew-symmetric if $\mathbf{A} = -\mathbf{A}^T$.) (2 points)

2) Let $\mathcal{F} = \{S_1, \dots, S_n\}$ be a family of distinct subspaces of a finite-dimensional vector space V such that $V = \sum_{i=1}^n S_i$. Prove that the following statements are equivalent:

- (Independence of the family)** For each i , $S_i \cap \left(\sum_{j \neq i} S_j\right) = \{0\}$.
- (Uniqueness of expression for 0)** The zero vector 0 cannot be written as a sum of nonzero vectors from distinct subspaces of \mathcal{F} .
- (Uniqueness of expression)** Every nonzero $v \in V$ has a unique, except for order of terms, expression as a sum $v = s_1 + \dots + s_n$ of nonzero vectors from distinct subspaces in \mathcal{F} .

(So a sum $V = \sum_{i=1}^n S_i$ is direct if and only if any one of the above statements holds.)

Hint: to prove the equivalence, you could show that, for example, a) implies b) and b) implies c) and c) implies a). (15 points)

1) explain:

- 两个不同的面，不能构成一个立体空间
- 因为上对角矩阵 A ，下对角矩阵 B ， $A \cap B =$ 对角线，交集不为空，所以不符合
- 考虑一个 $n \times n$ 的矩阵 A ，我们可以写成它的对称部分和反对称部分的和：

$$B = \frac{1}{2}(A + A^T) \quad \text{和} \quad C = \frac{1}{2}(A - A^T)$$

验证 B 和 C 分别是对称矩阵和反对称矩阵：

对于 B ：

$$B^T = \left(\frac{1}{2}(A + A^T)\right)^T = \frac{1}{2}(A^T + (A^T)^T) = \frac{1}{2}(A^T + A) = \frac{1}{2}(A + A^T) = B$$

所以 B 是对称矩阵。

对于 C:

$$C^T = \left(\frac{1}{2}(A - A^T) \right)^T = \frac{1}{2}((A - A^T)^T) = \frac{1}{2}(A^T - A) = -\frac{1}{2}(A - A^T) = -C$$

所以 C 是反对称矩阵。

因此, 我们得到了 $A = B + C$, 其中 B 是对称矩阵, C 是反对称矩阵, 并且这种分解是唯一的。这表明 $\mathbb{R}^{n \times n}$ 可以表示为对称矩阵和反对称矩阵的直和。

2) prove:

我们首先证明 a) 蕴含 b):

a) 对于每个 i , $S_i \cap \left(\sum_{j \neq i} S_j \right) = \{0\}$ 。

假设, 相反地, b) 是错误的, 这意味着零向量 $\mathbf{0}$ 可以被表示为来自 F 中不同子空间的非零向量之和。我们将这些非零向量表示为 v_1, v_2, \dots, v_k , 其中每个 v_j 属于不同的子空间 S_{i_j} 。然后我们有:

$$\mathbf{0} = v_1 + v_2 + \dots + v_k$$

这意味着 v_1, v_2, \dots, v_k 线性相关, 与 a) 中的假设矛盾。因此, 命题 b) 成立。

接下来, 我们证明 b) 蕴含 c):

b) 零向量 $\mathbf{0}$ 不能被表示为来自 F 中不同子空间的非零向量之和。

现在, 让 $v \in V$ 是一个非零向量。假设, 为了矛盾, 存在两个不同的表达式使得 v 可以被表示为来自 F 中不同子空间的非零向量之和:

$$v = s_1 + s_2 + \dots + s_k = t_1 + t_2 + \dots + t_m$$

其中每个 s_i 属于不同的子空间 S_{i_j} , 每个 t_j 属于不同的子空间 S_{j_l} 。那么:

$$s_1 + s_2 + \dots + s_k - (t_1 + t_2 + \dots + t_m) = \mathbf{0}$$

但这与 b) 中的假设矛盾。因此, 命题 c) 成立。

最后, 我们证明 c) 蕴含 a):

c) 每个非零 $v \in V$ 都可以唯一地表示为来自 F 中不同子空间的非零向量之和。

假设, 为了矛盾, 存在 i 使得 $S_i \cap \left(\sum_{j \neq i} S_j \right) \neq \{0\}$ 。这意味着存在一个非零向量 v 同时属于 S_i 和 $\sum_{j \neq i} S_j$ 。然而, 根据命题 c), v 必须有一个唯一的表达式, 表示为来自不同子空间的非零向量之和, 这与 v 同时属于 S_i 和 $\sum_{j \neq i} S_j$ 的事实相矛盾。因此, 命题 a) 成立。

综上所述, 证毕。

Problem 4. (Grassmann Formula) (10 points)

Let S and T be subspaces of a finite-dimensional vector space V . Please prove the following formula

$$\dim(S) + \dim(T) = \dim(S + T) + \dim(S \cap T).$$

In particular, if T is any complement of S in V , then

$$\dim(S) + \dim(T) = \dim(V),$$

that is, the dimensions of vector spaces are additive in a direct sum:

$$\dim(S \oplus T) = \dim(S) + \dim(T).$$

Hint: to prove the first formula, you might start by considering a basis for $S \cap T$, and extending it to bases for S and T separately. With these bases, then consider how to construct a basis for $S + T$ and prove that it is a basis indeed.

prove:

假设 β_1, \dots, β_k 是 $S \cap T$ 的基。由于 $S \cap T$ 是 S 的一个子空间, 我们可以将 β_1, \dots, β_k 扩充为 S 的一组基 $\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_k$ 。同样地, 我们也可以将 β_1, \dots, β_k 扩充为 T 的一组基 $\beta_1, \dots, \beta_k, \gamma_1, \dots, \gamma_t$ 。

我们首先说明 $\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_k, \gamma_1, \dots, \gamma_t$ 是线性无关的。如果它们线性相关, 那么一定存在不全为零的 $a_1, \dots, a_s, b_1, \dots, b_k, c_1, \dots, c_t$, 使得:

$$a_1\alpha_1 + \dots + a_s\alpha_s + b_1\beta_1 + \dots + b_k\beta_k = c_1\gamma_1 + \dots + c_t\gamma_t$$

上式的左边在 S 中, 右边在 T 中。因此, $c_1\gamma_1 + \dots + c_t\gamma_t \in S \cap T$ 。由于 $\gamma_1, \dots, \gamma_t$ 的选择, 知道它们都不在 $S \cap T$ 中, 因此 $c_1 = \dots = c_t = 0$ 。同样的道理可以知道 $a_1, \dots, a_s, b_1, \dots, b_k$ 也必须都是零。所以 $\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_k, \gamma_1, \dots, \gamma_t$ 是线性无关的。

其次我们说明 $\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_k, \gamma_1, \dots, \gamma_t$ 能够张成 $S + T$ 。这是因为 $\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_k$ 能张成 S , $\beta_1, \dots, \beta_k, \gamma_1, \dots, \gamma_t$ 能够张成 T 。所以它们合在一起能够张成 $S + T$ 。

因此 $\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_k, \gamma_1, \dots, \gamma_t$ 是 $S + T$ 的一组基。所以

$$\dim(S + T) = s + k + t = \dim S + \dim T - \dim(S \cap T)$$

$$\dim(S + T) + \dim(S \cap T) = \dim S + \dim T$$

Problem 5. (Block Matrix Computations) (20 points)

Let \mathbf{S} as the sample covariance matrix of n independent observed samples of a p -variate Gaussian random variable with zero mean and covariance matrix $\mathbf{\Sigma} \in \mathbb{R}^{p \times p}$. Denote σ_{ij} as the ij -th entry in $\mathbf{\Sigma}$. Suppose four elements $\{\sigma_{11}, \sigma_{12}, \sigma_{21}, \sigma_{22}\}$ in $\mathbf{\Sigma}$ are missing as

$$\mathbf{\Sigma} = \begin{bmatrix} ? & ? & \cdots \\ ? & ? & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}.$$

Our goal is to estimate the missing entries based on the observed ones in $\mathbf{\Sigma}$ and the sample covariance matrix \mathbf{S} . Given

$$\mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}_{AA} & \mathbf{\Sigma}_{AB} \\ \mathbf{\Sigma}_{AB} & \mathbf{\Sigma}_{BB} \end{bmatrix}, \quad \text{with} \quad \mathbf{\Sigma}_{AA} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}.$$

We are interested in the following Gaussian maximum likelihood estimation problem for $\mathbf{\Sigma}_{AA}$:

$$\min_{\mathbf{\Sigma}_{AA}} \text{tr}(\mathbf{S}\mathbf{\Sigma}^{-1}) + \log \det(\mathbf{\Sigma}). \quad (1)$$

- 1) If $\mathbf{\Sigma}_{AA}$ is invertible, it easy to verify that the above 2×2 partitioned $\mathbf{\Sigma}$ has the following factorization form

$$\mathbf{\Sigma} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{\Sigma}_{BA}\mathbf{\Sigma}_{AA}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{\Sigma}_{AA} & \mathbf{0} \\ \mathbf{0} & \mathbf{\Sigma}_{BB} - \mathbf{\Sigma}_{BA}\mathbf{\Sigma}_{AA}^{-1}\mathbf{\Sigma}_{AB} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{\Sigma}_{AA}^{-1}\mathbf{\Sigma}_{AB} \\ \mathbf{0} & \mathbf{I} \end{bmatrix}. \quad (2)$$

(Note: $\mathbf{\Sigma}_{BB} - \mathbf{\Sigma}_{BA}\mathbf{\Sigma}_{AA}^{-1}\mathbf{\Sigma}_{AB}$ is named *Schur complement* of $\mathbf{\Sigma}_{AA}$ in the matrix literature.)

- Based on the above factorization result, compute the inverse and determinant of $\mathbf{\Sigma}$. (5 points)
- Write the objective function in (7) explicitly as a function of variable $\mathbf{\Sigma}_{AA}$. (5 points)

Hint: You may need to partition \mathbf{S} as

$$\mathbf{S} = \begin{bmatrix} \mathbf{S}_{AA} & \mathbf{S}_{AB} \\ \mathbf{S}_{BA} & \mathbf{S}_{BB} \end{bmatrix},$$

where \mathbf{S}_{AA} , \mathbf{S}_{AB} , \mathbf{S}_{BA} and \mathbf{S}_{BB} take the same dimension as $\mathbf{\Sigma}_{AA}$, $\mathbf{\Sigma}_{AB}$, $\mathbf{\Sigma}_{BA}$, and $\mathbf{\Sigma}_{BB}$, respectively.

- Directly solving for $\mathbf{\Sigma}_{AA}$ based on the objective function derived above is difficult, one alternative way is to solve for an intermediate variable $\tilde{\mathbf{\Sigma}}_{AA} = \mathbf{\Sigma}_{AA} - \mathbf{\Sigma}_{AB}\mathbf{\Sigma}_{BB}^{-1}\mathbf{\Sigma}_{BA}$.
 - Mimicking the form of (6), decompose $\mathbf{\Sigma}$ into the product of three matrices, where $\tilde{\mathbf{\Sigma}}_{AA}$ shows up. (4 points)
 - Try to derive the objective function in terms of $\tilde{\mathbf{\Sigma}}_{AA}$ and discuss why the resulting problem is easier than the one you derived in 1.b). (6 points)

Hint: $\tilde{\Sigma}_{AA}$ is the Schur complement of Σ_{BB} . Deriving the objective function in terms of $\tilde{\Sigma}_{AA}$ may require a similar proof as that in the previous question.

1) solve:

a)

$$\Sigma^{-1} = \begin{bmatrix} \mathbf{I} & -\Sigma_{AA}^{-1}\Sigma_{AB} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma_{BB} - \Sigma_{BA}\Sigma_{AA}^{-1}\Sigma_{AB} & \mathbf{0} \\ \mathbf{0} & \Sigma_{AA} \end{bmatrix} \begin{bmatrix} \mathbf{I} \\ \mathbf{0} - \Sigma_{BA}\Sigma_{AA}^{-1} & \mathbf{I} \end{bmatrix}. \quad (3)$$

$$\det(\Sigma) = \det(\mathbf{A})\det(\mathbf{S}_\mathbf{A})$$

b) objective function :

$$\min_{\Sigma_{AA}} \text{tr}(\mathbf{S}\Sigma^{-1}) + \log \det(\Sigma). \quad (4)$$

$$\min_{\Sigma_{AA}} \text{tr} \left(\begin{bmatrix} S_{AA} & S_{AB} \\ S_{BA} & S_{BB} \end{bmatrix} \Sigma_{-1} \right) + \log \det(\Sigma). \quad (5)$$

2) a) solve:

$$\Sigma = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \Sigma_{AB}\Sigma_{BB}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma_{BB} & \mathbf{0} \\ \mathbf{0} & \Sigma_{AA} - \Sigma_{AB}\Sigma_{BB}^{-1}\Sigma_{BA} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \Sigma_{BB}^{-1}\Sigma_{BA} \\ \mathbf{0} & \mathbf{I} \end{bmatrix}. \quad (6)$$

b) objective function :

$$\min_{\Sigma_{BB}} \text{tr}(\mathbf{S}\Sigma^{-1}) + \log \det(\Sigma). \quad (7)$$

Problem 6. (Determinant) (20 points)

Consider the following matrices

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 6 & 2 & 1 \\ -2 & 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 & 0 & -2 & 3 \\ 1 & 0 & 1 & 2 \\ -1 & 1 & 2 & 1 \\ 0 & 2 & -3 & 0 \end{bmatrix}.$$

- 1) Use a cofactor expansion to evaluate the determinants $\det(\mathbf{A})$ and $\det(\mathbf{B})$. (10 points)
- 2) Use determinants and adjugate matrices to compute the inverses \mathbf{A}^{-1} and \mathbf{B}^{-1} . (10 points)

1)

$$\det(\mathbf{A}) = 2 * \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} - 1 * \begin{bmatrix} 6 & 1 \\ -2 & 1 \end{bmatrix} + 1 * \begin{bmatrix} 6 & 2 \\ -2 & 2 \end{bmatrix} = 8$$

同理: $\det(\mathbf{B}) = 15$

2)

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 0 & 1 & -1 \\ -8 & 4 & -4 \\ 16 & -6 & -2 \end{bmatrix} \quad \mathbf{B}^{-1} = \frac{1}{39} \begin{bmatrix} -12 & 25 & -14 & 7 \\ -9 & 9 & 9 & 15 \\ -6 & 6 & 6 & -3 \\ 9 & 4 & 4 & -2 \end{bmatrix}$$